



Analítica de Datos


Clase 5 - Métricas


Agenda

- Métricas
- Práctica









Métricas de regresión

Métricas de regresión

Métrica	Qué mide	Interpretación simple
MAE	Error absoluto promedio	En promedio, cuánto me equivoco
MSE	Error cuadrático promedio	Penaliza mucho los errores grandes
RMSE	Raíz del MSE	Error típico, en la misma unidad que Y
R²	Varianza explicada	Qué proporción de la variabilidad explica el modelo
R² ajustado	R² considerando cantidad de variables	Penaliza agregar variables que aportan poco

Métricas de error

MAE (Mean Absolute Error): Calcula cuánto se equivoca el modelo en promedio, tomando el valor absoluto de cada error.

Es fácil de interpretar porque queda expresado en la misma unidad que la variable que estamos prediciendo.

$$MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$$

MSE (Mean Squared Error): Calcula el promedio de los errores elevados al cuadrado.

Al elevarlos al cuadrado, penaliza mucho más los errores grandes que los pequeños.

$$MSE = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$$

RMSE (Root Mean Squared Error): Es la raíz cuadrada del MSE, por lo que también penaliza más los errores grandes.

A diferencia del MSE, vuelve a estar expresado en la misma unidad que la variable predicha, facilitando su interpretación.

$$RMSE = \sqrt{MSE}$$

Métricas de error

R^2 (Coeficiente de determinación):

Mide qué proporción de la variabilidad de la variable objetivo logra explicar el modelo.

Por ejemplo, un $R^2 = 0,80$ indica que el modelo explica aproximadamente el 80% de la variabilidad observada en los datos.

Métricas de clasificación

		Real	
		1	0
Predicho	1		
	0		

		Real	
		1	0
Predicho	1	True Positive	
	0		

		Real	
		1	0
Predicho	1	True Positive	
	0		True Negative

		Real	
		1	0
Predicho	1	True Positive	False Positive
	0		True Negative

		Real	
		1	0
Predicho	1	True Positive	False Positive
	0	False Negative	True Negative

		Real	
		1	0
Predicho	1	15	3
	0	8	23

Leamos esta matriz

		Real	
		1	0
Predicho	1	15	3
	0	8	23

		Real	
		1	0
Predicho	1	15	3
	0	8	23

Leamos esta matriz

¿Cuántas veces acerté?

		Real	
		1	0
Predicho	1	15	3
	0	8	23

Leamos esta matriz

¿Cuántas veces acerté?

¿Cuántas veces no acerté?

		Real	
		1	0
Predicho	1	15	3
	0	8	23

Leamos esta matriz

¿Cuántas veces acerté?

¿Cuántas veces no acerté?

¿Cuántos falsos positivos tengo?

		Real	
		1	0
Predicho	1	15	3
	0	8	23

Leamos esta matriz

¿Cuántas veces acerté?

¿Cuántas veces no acerté?

¿Cuántos falsos positivos tengo?

¿Cuántos falsos negativos tengo?

		Real	
		1	0
Predicho	1	15	3
	0	8	23

Leamos esta matriz

¿Cuántas veces acerté?

¿Cuántas veces no acerté?

¿Cuántos falsos positivos tengo?

¿Cuántos falsos negativos tengo?

¿Mi modelo es bueno?

Métricas

Métricas

Accuracy (Exactitud)

Precision (Precisión)

Recall / Sensibilidad / TPR

Specificity (Especificidad / TNR)

F1-Score

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Métricas

Accuracy (Exactitud)

Precision (Precisión)

Recall / Sensibilidad / TPR

Specificity (Especificidad / TNR)

F1-Score

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Accuracy

$$Accuracy = \frac{VP + VN}{VP + VN + FP + FN}$$

Predicho

- % de aciertos totales
- Problema: engañosa en datasets desbalanceados

		Real	
		1	0
1	1	VP	FP
	0	FN	VN

Accuracy

$$Accuracy = \frac{VP + VN}{VP + VN + FP + FN}$$

Predicho

		Real	
		1	0
1	1	VP 15	FP 3
	0	FN 8	VN 23

Accuracy

$$Accuracy = \frac{VP + VN}{VP + VN + FP + FN}$$
$$\frac{15 + 23}{15 + 23 + 3 + 8} = 77,55\%$$

Predicho

		Real	
		1	0
1	VP	15	3
	FP		
0	FN	8	23
	VN		

Qué porcentaje total de veces el modelo acierta.

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión)

Recall / Sensibilidad / TPR

Specificity (Especificidad / TNR)

F1-Score

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión)

Recall / Sensibilidad / TPR

Specificity (Especificidad / TNR)

F1-Score

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Precision

$$Precision = \frac{VP}{VP + FP}$$

- Qué tan confiables son los positivos
- Minimiza falsos positivos

Predicho

		Real	
		1	0
1	1	VP	FP
	0	FN	VN

Precision

$$Precision = \frac{VP}{VP + FP}$$

Predicho

		Real	
		1	0
1	1	VP 15	FP 3
	0	FN 8	VN 23

Precision

$$Precision = \frac{VP}{VP + FP}$$

$$\frac{15}{15 + 3} = 83,33\%$$

Predicho

		Real	
		1	0
1	1	VP 15	FP 3
	0	FN 8	VN 23

Precision

$$Precision = \frac{VP}{VP + FP}$$

$$\frac{15}{15 + 3} = 83,33\%$$

Predicho

		Real	
		1	0
1	1	VP 15	FP 3
	0	FN 8	VN 23

Cuando el modelo dice “sí”, qué tan seguido tiene razón.

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión): proporción de predicciones positivas que realmente son correctas.

Recall / Sensibilidad / TPR

Specificity (Especificidad / TNR)

F1-Score

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión): proporción de predicciones positivas que realmente son correctas.

Recall / Sensibilidad / TPR

Specificity (Especificidad / TNR)

F1-Score

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Recall

$$\text{Recall} = \frac{VP}{VP + FN}$$

Predicho

- Qué tan bien detecta los positivos reales
- Minimiza falsos negativos

		Real	
		1	0
Predicho	1	VP	FP
	0	FN	VN

Recall

$$\text{Recall} = \frac{VP}{VP + FN}$$

Predicho

		Real	
		1	0
1	1	VP 15	FP 3
	0	FN 8	VN 23

Recall

$$\text{Recall} = \frac{VP}{VP + FN}$$

$$\frac{15}{15 + 8} = 65,22\%$$

Predicho

		Real	
		1	0
Predicho	1	VP 15	FP 3
	0	FN 8	VN 23

De todos los casos positivos reales, cuántos logra encontrar el modelo.

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión): proporción de predicciones positivas que realmente son correctas.

Recall / Sensibilidad / TPR: proporción de casos positivos reales que el modelo logra detectar.

Specificity (Especificidad / TNR)

F1-Score

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión): proporción de predicciones positivas que realmente son correctas.

Recall / Sensibilidad / TPR: proporción de casos positivos reales que el modelo logra detectar.

Specificity (Especificidad / TNR)

F1-Score

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Specificity

$$\textit{Specificity} = \frac{VN}{VN + FP}$$

- Qué tan bien detecta negativos

Predicho

		Real	
		1	0
1	1	VP	FP
	0	FN	VN

Specificity

$$\textit{Specificity} = \frac{VN}{VN + FP}$$

Predicho

		Real	
		1	0
1	1	VP 15	FP 3
	0	FN 8	VN 23

Specificity

$$\text{Specificity} = \frac{VN}{VN + FP}$$
$$\frac{23}{23 + 3} = 88,46\%$$

Predicho

		Real	
		1	0
Predicho	1	VP 15	FP 3
	0	FN 8	VN 23

De todos los casos negativos reales, cuántos identifica correctamente.

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión): proporción de predicciones positivas que realmente son correctas.

Recall / Sensibilidad / TPR: proporción de casos positivos reales que el modelo logra detectar.

Specificity (Especificidad / TNR): proporción de casos negativos reales que el modelo identifica correctamente.

F1-Score

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión): proporción de predicciones positivas que realmente son correctas.

Recall / Sensibilidad / TPR: proporción de casos positivos reales que el modelo logra detectar.

Specificity (Especificidad / TNR): proporción de casos negativos reales que el modelo identifica correctamente.

F1-Score

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

F1-score

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

- Balance entre precision y recall
- Clave en clases desbalanceadas

Predicho

		Real	
		1	0
1	1	VP	FP
	0	FN	VN

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión): proporción de predicciones positivas que realmente son correctas.

Recall / Sensibilidad / TPR: proporción de casos positivos reales que el modelo logra detectar.

Specificity (Especificidad / TNR): proporción de casos negativos reales que el modelo identifica correctamente.

F1-Score: una forma de combinar precision y recall en un solo número balanceado.

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión): proporción de predicciones positivas que realmente son correctas.

Recall / Sensibilidad / TPR: proporción de casos positivos reales que el modelo logra detectar.

Specificity (Especificidad / TNR): proporción de casos negativos reales que el modelo identifica correctamente.

F1-Score: una forma de combinar precision y recall en un solo número balanceado.

False Positive Rate (FPR / Fall-out)

False Negative Rate (FNR / Miss Rate)

False Discovery Rate (FDR)

False Omission Rate (FOR)

Negative Predictive Value (NPV)

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

FPR:	$\frac{FP}{FP+VN}$	→ de los negativos reales, cuántos el modelo clasifica mal como positivos.
FNR:	$\frac{FN}{FN+VP}$	→ de los positivos reales, cuántos el modelo no logra detectar.
FDR:	$\frac{FP}{FP+VP}$	→ de los casos que el modelo predijo como positivos, cuántos son errores.
FOR:	$\frac{FN}{FN+VN}$	→ de los casos que el modelo predijo como negativos, cuántos en realidad eran positivos.
NPV:	$\frac{VN}{VN+FN}$	→ de los casos que el modelo predijo como negativos, cuántos son correctos.

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión): proporción de predicciones positivas que realmente son correctas.

Recall / Sensibilidad / TPR: proporción de casos positivos reales que el modelo logra detectar.

Specificity (Especificidad / TNR): proporción de casos negativos reales que el modelo identifica correctamente.

F1-Score: una forma de combinar precision y recall en un solo número balanceado.

False Positive Rate (FPR): de los negativos, cuántos el modelo marca mal como positivos.

False Negative Rate (FNR): de los positivos, cuántos el modelo deja pasar sin detectar.

False Discovery Rate (FDR): de los casos que el modelo marcó como positivos, cuántos son errores.

False Omission Rate (FOR): de los casos que el modelo marcó como negativos, cuántos en realidad eran positivos.

Negative Predictive Value (NPV): cuando el modelo dice “no”, qué tan seguido tiene razón.

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Métricas

Accuracy (Exactitud): proporción total de predicciones correctas sobre el total de casos.

Precision (Precisión): proporción de predicciones positivas que realmente son correctas.

Recall / Sensibilidad / TPR: proporción de casos positivos reales que el modelo logra detectar.

Specificity (Especificidad / TNR): proporción de casos negativos reales que el modelo identifica correctamente.

F1-Score: una forma de combinar precision y recall en un solo número balanceado.

False Positive Rate (FPR): de los negativos, cuántos el modelo marca mal como positivos.

False Negative Rate (FNR): de los positivos, cuántos el modelo deja pasar sin detectar.

False Discovery Rate (FDR): de los casos que el modelo marcó como positivos, cuántos son errores.

False Omission Rate (FOR): de los casos que el modelo marcó como negativos, cuántos en realidad eran positivos.

Negative Predictive Value (NPV): cuando el modelo dice “no”, qué tan seguido tiene razón.

Curva ROC

AUC (Area Under the Curve)

Curva Precision-Recall (PR)

Curva ROC

Las curvas ROC (Receiver Operating Characteristic) son una representación gráfica fundamental para evaluar el rendimiento de un modelo de clasificación binaria.

Curva ROC

Las curvas ROC (Receiver Operating Characteristic) son una representación gráfica fundamental para evaluar el rendimiento de un modelo de clasificación binaria.

Muestra cómo varían la **sensibilidad** y la **especificidad** del modelo al modificar los umbrales de decisión de los scores de predicción.

Curva ROC

Las curvas ROC (Receiver Operating Characteristic) son una representación gráfica fundamental para evaluar el rendimiento de un modelo de clasificación binaria.

Muestra cómo varían la **sensibilidad** y la **especificidad** del modelo al modificar los umbrales de decisión de los scores de predicción.

¿Qué es un umbral de decisión?

Curva ROC

Las curvas ROC (Receiver Operating Characteristic) son una representación gráfica fundamental para evaluar el rendimiento de un modelo de clasificación binaria.


Muestra cómo varían la **sensibilidad** y la **especificidad** del modelo al modificar los umbrales de decisión de los scores de predicción.

Esta curva se construye a partir de dos métricas clave:

Tasa de verdaderos positivos (TPR): sensibilidad, indica la proporción de positivos correctamente clasificados.

Tasa de falsos positivos (FPR): muestra cuántos negativos han sido incorrectamente clasificados como positivos.

Curva ROC



¿Qué muestra la curva ROC?

Cada punto de la curva corresponde a un umbral de decisión distinto.

A medida que bajamos el umbral:

- Aumenta el TPR (detectamos más positivos)
- También aumenta el FPR (cometemos más falsos positivos)

Interpretación:


- Curva más cerca de la esquina superior izquierda (0,1) = mejor modelo.
- Línea diagonal (gris) = el modelo no tiene capacidad de discriminar (azar).

Recordatorio: Matriz de confusión

		Predicción del modelo	
		Positivo	Negativo
Valor real	Positivo	VP (verdadero positivo)	FN (falso negativo)
	Negativo	FP (falso positivo)	VN (verdadero negativo)




En resumen: La curva ROC nos permite evaluar el rendimiento del modelo en todos los umbrales posibles y elegir el que mejor equilibrio logre entre detectar positivos y evitar falsos positivos.



Sin entrenar: ROC AUC=0.500


Regresión Logística: ROC AUC=0.903



Curva ROC - A tener en cuenta

1. No es una métrica, es una herramienta visual


Sin entrenar: ROC AUC=0.500
Regresión Logística: ROC AUC=0.903



Curva ROC - A tener en cuenta

1. No es una métrica, es una herramienta visual
2. Muestra el trade-off clave del modelo
 - Más recall (detectás más positivos)
 - Más falsos positivos (más errores)Para detectar más, tengo que equivocarme más

Sin entrenar: ROC AUC=0.500
Regresión Logística: ROC AUC=0.903



Curva ROC - A tener en cuenta

1. No es una métrica, es una herramienta visual

2. Muestra el trade-off clave del modelo


- Más recall (detectás más positivos)
- Más falsos positivos (más errores)

Para detectar más, tengo que equivocarme más

3. Qué significa que una curva sea “mejor”

- Más cerca de la esquina superior izquierda → mejor modelo
- Pegada a la diagonal → modelo malo (azar)

Sin entrenar: ROC AUC=0.500
Regresión Logística: ROC AUC=0.903



AUC: Area Under Curve

El valor del **AUC** (Área Bajo la Curva ROC) indica qué tan bien un modelo de clasificación binaria es capaz de distinguir entre clases positivas y negativas.

AUC: Area Under Curve

El valor del **AUC** (Área Bajo la Curva ROC) indica qué tan bien un modelo de clasificación binaria es capaz de distinguir entre clases positivas y negativas.

Dependiendo del rendimiento del modelo, el AUC puede tomar los siguientes valores

AUC: Area Under Curve

El valor del **AUC** (Área Bajo la Curva ROC) indica qué tan bien un modelo de clasificación binaria es capaz de distinguir entre clases positivas y negativas.

Dependiendo del rendimiento del modelo, el AUC puede tomar los siguientes valores

AUC = 1: El modelo es perfecto, clasifica correctamente todas las instancias positivas y negativas sin errores.


AUC > 0.5: El modelo es mejor que el azar, tiene una capacidad significativa para diferenciar entre clases.

AUC = 0.5: El modelo tiene un comportamiento similar al azar, sin capacidad real de clasificación.

AUC < 0.5: El modelo es peor que el azar, clasifica incorrectamente con más frecuencia de lo esperado.

AUC (Área Bajo la Curva ROC)

El AUC resume en un solo número el desempeño global del modelo.



¿Qué es el AUC?

 El AUC (Area Under the Curve) es el área bajo la curva ROC. Representa la probabilidad de que el modelo asigne una puntuación más alta a un positivo que a un negativo elegido al azar.

¿Cómo se interpreta?







- **AUC = 1.0** → Discriminación perfecta
- **AUC = 0.5** → No mejor que el azar
- **AUC entre 0.5 y 1.0** → Mejor capacidad de discriminación cuanto más se acerque a 1
- **AUC < 0.5** → Peor que el azar (el modelo podría estar invertido)

Ejemplos de interpretación del AUC	
AUC	Interpretación
0.90 – 1.00	Excelente
0.80 – 0.90	Muy bueno
0.70 – 0.80	Aceptable
0.60 – 0.70	Bajo
0.50 – 0.60	Pobre
< 0.50	Peor que el azar (invertido)



En resumen: El AUC mide qué tan bien el modelo separa positivos de negativos en todos los umbrales posibles. Cuanto mayor sea el AUC, mejor será la capacidad del modelo para discriminar entre clases.

clasificador ideal**clasificador aleatorio****“buen” clasificador****“mal” clasificador**

Curva Precision-Recall

- Muestra el equilibrio entre encontrar positivos (recall) y no equivocarse al marcarlos (precision).

Curva Precision-Recall


- Muestra el equilibrio entre encontrar positivos (recall) y no equivocarse al marcarlos (precision).
- Es especialmente útil cuando las clases están desbalanceadas o los positivos son pocos.

Curva Precision-Recall

- Muestra el equilibrio entre encontrar positivos (recall) y no equivocarse al marcarlos (precision).
- Es especialmente útil cuando las clases están desbalanceadas o los positivos son pocos.
- Permite evaluar qué tan confiables son las predicciones positivas a medida que cambia el umbral.

Curva Precision-Recall (PR)

Muestra el equilibrio entre **Precision** (qué tan bien acierta cuando dice "sí") y **Recall** (cuántos positivos logra encontrar) para todos los umbrales posibles.



¿Qué muestra la curva PR?

- Cada punto corresponde a un umbral distinto.
- Al bajar el umbral:
 - Aumenta el Recall (encontramos más positivos)
 - Disminuye la Precision (nos equivocamos más al decir "sí")

¿Cómo interpretarla?

- Mejor modelo** → curva más arriba y más a la derecha. Mantiene alta precision incluso con alto recall.
- Línea base (azar)** → precision = proporción de positivos en los datos (prevalencia). Cualquier modelo útil debe estar por encima de esa línea.
- No existe un punto "perfecto": elige el umbral según el costo de los errores en tu problema.

¿Cuándo usarla?

- Especialmente útil cuando las clases están desbalanceadas (los positivos son pocos).
- En estos casos, la curva ROC puede verse "optimista", mientras que la PR refleja mejor el rendimiento real en los positivos.

¿Qué es Precision y Recall?

Precision (PPV):
De todas las predicciones positivas, ¿cuántas son correctas?
 $VP / (VP + FP)$

Recall (Sensibilidad):
De todos los positivos reales, ¿cuántos logró detectar el modelo?
 $VP / (VP + FN)$

Comparación rápida: ROC vs PR		
Aspecto	Curva ROC	Curva PR
Ejes	TPR (Recall) vs FPR	Precision vs Recall
Enfoque	Todos los ejemplos (positivos y negativos)	Solo se enfoca en los positivos
Desbalance de clases	Puede verse bien aunque el modelo sea malo con positivos raros	Más informativa cuando los positivos son pocos
Interpretación	Capacidad de discriminar	Calidad vs cobertura de positivos

En resumen: La curva PR muestra qué tan bien el modelo encuentra positivos (sensibilidad) sin equivocarse demasiado (precision). Cuanto más cerca esté la curva de la esquina superior derecha, mejor será el modelo.

Recordatorio: Matriz de confusión

VP: Verdadero Positivo

FP: Falso Positivo

FN: Falso Negativo

VN: Verdadero Negativo

Diferencias entre ROC y PR

1. Qué miden

ROC: relación entre verdaderos positivos (TPR) y falsos positivos (FPR)

PR: relación entre precision y recall

2. En qué se enfocan

ROC: evalúa el desempeño general del modelo (positivos y negativos)

PR: se enfoca solo en la calidad de los positivos

3. Sensibilidad al desbalance de clases

ROC: puede verse “optimista” cuando hay muchas clases negativas

PR: refleja mejor el rendimiento cuando los positivos son pocos

Diferencias entre ROC y PR

4. Interpretación

ROC: qué tan bien separa clases

PR: qué tan bien encuentra positivos sin equivocarse

5. Cuándo usar cada una

ROC:

- clases balanceadas
- interés general del modelo

PR:

- clases desbalanceadas
- positivos raros (fraude, cáncer, spam)

Métricas en Python

```
#Confusion matrix metrics  
matrix = classification_report(y_test,pred)  
print('Classification report : \n',matrix)
```

```
Classification report :  
              precision    recall  f1-score   support  
  
     0       0.83         0.86         0.85         29  
     1       0.87         0.84         0.86         32  
  
accuracy              0.85         0.85         0.85         61  
macro avg              0.85         0.85         0.85         61  
weighted avg           0.85         0.85         0.85         61
```

Análisis de puntos de dolor

RESULTADOS
MATRIZ DE CONFUSIÓN

PRESENTE


AUSENTE

PREDICCIÓN

PRESENTE

REALIDAD

AUSENTE



Métricas del modelo; N = 140,643		
Métrica	Modelo Accuracy	Modelo Recall
Accuracy	0.65	0.61
AUC	0.732	0.721
Recall	0.72	0.83
Especificidad	0.60	0.48
Precisión	0.52	0.48
F1-score	0.60	0.61

¿Como se ve reflejado en casos reales?

Detección de enfermedades

Imaginense que están trabajando en un modelo que analiza estudios médicos para detectar una enfermedad severa.

Detección de enfermedades

Imaginense que están trabajando en un modelo que analiza estudios médicos para detectar una enfermedad severa.

El sistema indica quienes son las personas con mayor probabilidad de tener esa enfermedad, e indica un doble chequeo para quienes el modelo indica positivo

Detección de enfermedades

Imaginense que están trabajando en un modelo que analiza estudios médicos para detectar una enfermedad severa.

El sistema indica quienes son las personas con mayor probabilidad de tener esa enfermedad, e indica un doble chequeo para quienes el modelo indica positivo

¿Qué métrica priorizarían?

Detección de enfermedades

Imaginense que están trabajando en un modelo que analiza estudios médicos para detectar una enfermedad severa.

El sistema indica quienes son las personas con mayor probabilidad de tener esa enfermedad, e indica un doble chequeo para quienes el modelo indica positivo

¿Qué métrica priorizarían?

Pista: El chequeo no tiene ningún efecto secundario, ni costo para la persona ni el hospital

Detección de enfermedades

Recall

Detección de enfermedades

Recall

Mi objetivo es detectar la mayor cantidad posible de enfermos

Incluso si el modelo genera falsos positivos (personas sanas que se revisan de más), eso es aceptable comparado con no detectar un caso real.

Detección de enfermedades

Recall

Mi objetivo es detectar la mayor cantidad posible de enfermos

Incluso si el modelo genera falsos positivos (personas sanas que se revisan de más), eso es aceptable comparado con no detectar un caso real.

Análisis de costo

Detección de fraude

Sos un banco que está armando un modelo de predicción para predecir si una transacción es fraudulenta

Detección de fraude

Sos un banco que está armando un modelo de predicción para predecir si una transacción es fraudulenta

Si el banco detecta fraude, bloquea la operación.

Pero si se equivoca, te bloquea una compra legítima (muy molesto).

Detección de fraude

Sos un banco que está armando un modelo de predicción para predecir si una transacción es fraudulenta

Si el banco detecta fraude, bloquea la operación.

Pero si se equivoca, te bloquea una compra legítima (muy molesto).

¿Que métrica usarían?

Detección de fraude

Sos un banco que está armando un modelo de predicción para predecir si una transacción es fraudulenta

Si el banco detecta fraude, bloquea la operación.

Pero si se equivoca, te bloquea una compra legítima (muy molesto).

¿Que métrica usarían?

Pista: Busquen un equilibrio entre los errores

Detección de fraude

F1-Score

Acá hay dos tensiones:

Detectar fraudes → Recall

No molestar clientes → Precision

Detección de fraude

F1-Score

Acá hay dos tensiones:

Detectar fraudes → Recall

No molestar clientes → Precision

¿Cual otra podrían usar?

Detección de fraude

F1-Score

Acá hay dos tensiones:

Detectar fraudes → Recall

No molestar clientes → Precision

¿Cual otra podrían usar?

Accuracy

Detección de fraude

F1-Score

Acá hay dos tensiones:

Detectar fraudes → Recall

No molestar clientes → Precision

¿Cual otra podrían usar?

Accuracy

¿Qué condición se tiene que cumplir?

Spam Detection

Están trabajando en el área de IA de Gmail, y están desarrollando un modelo de ML para predecir si un Mail es Spam o No

Spam Detection

Están trabajando en el área de IA de Gmail, y están desarrollando un modelo de ML para predecir si un Mail es Spam o No

¿Qué métrica usarían?

Spam Detection

Están trabajando en el área de IA de Gmail, y están desarrollando un modelo de ML para predecir si un Mail es Spam o No

¿Qué métrica usarían?

Piensen en el costo errores

¿Qué es peor: Dejar pasar un mail que es Spam, o clasificar un mail que no es Spam como Spam??

Spam Detection

Precision

No importa tanto dejar pasar algún spam (FN), pero sí evitar bloquear mails importantes (FP).

Quiero agarrar solo los que estoy muy seguro que son positivos

Piensen ustedes

Recall

F1

Precision

Listo