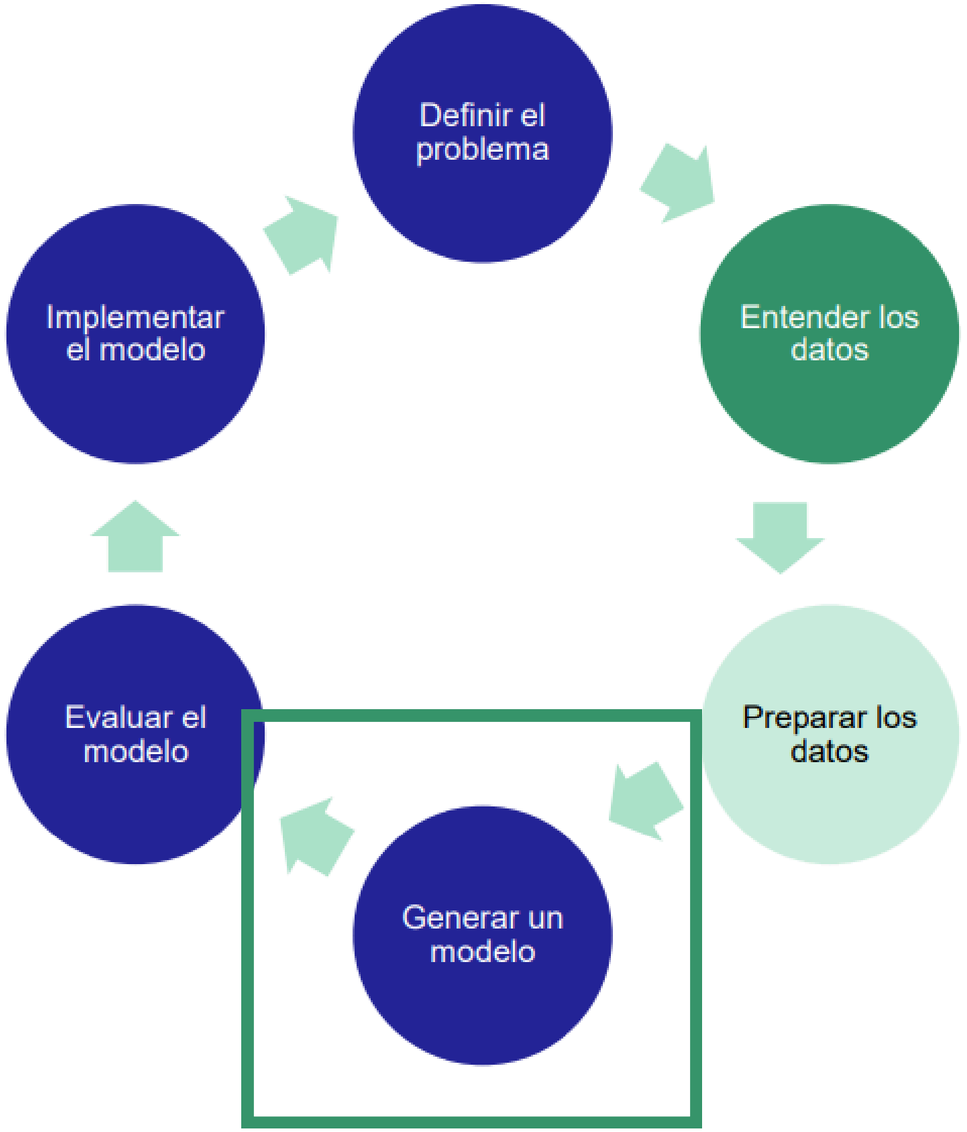
Analítica de Datos

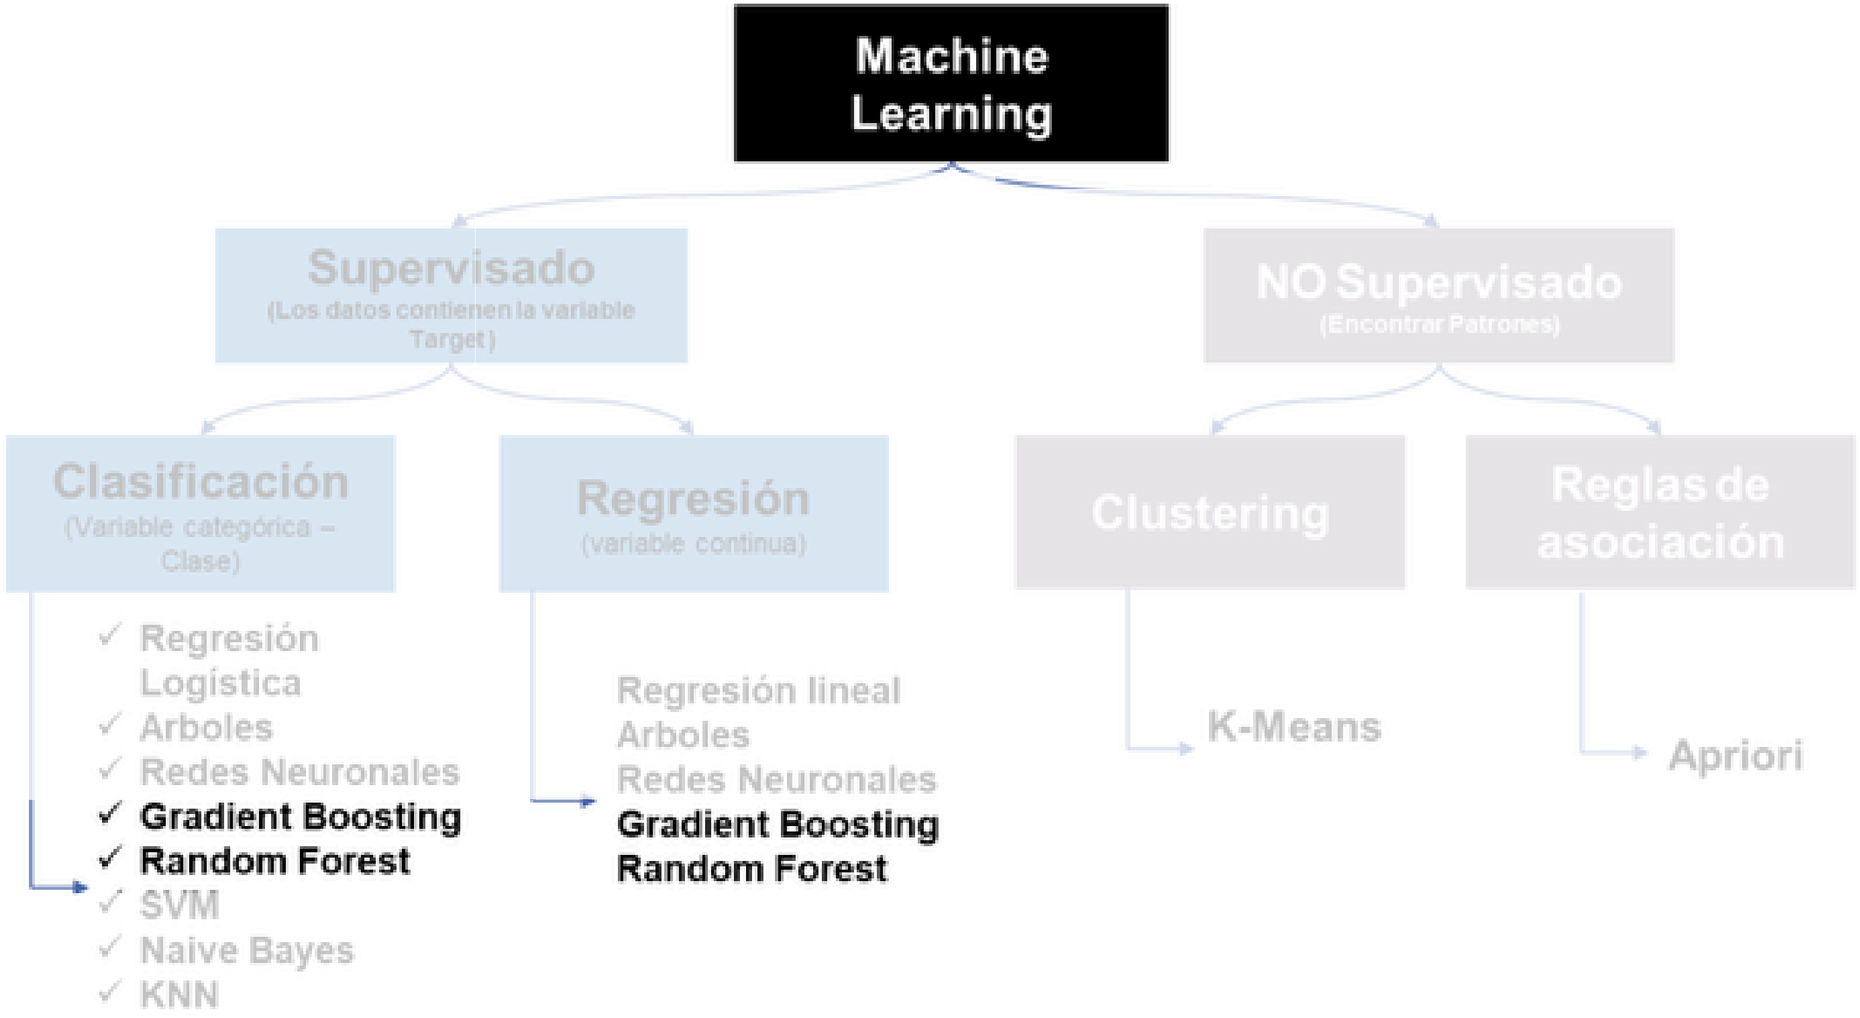
Clase 8 - Random Forest y Boosting

Teórica

Agenda

- Métodos de ensamble
- Random Forest
- Boosting
- Caso de aplicación


Definir el problema
Entender los datos
Preparar los datos
Generar un modelo
Evaluar el modelo
Implementar el modelo


Machine Learning
Supervisado
(Los datos contienen la variable Target)
NO Supervisado
(Encontrar Patrones)
Clasificación
(Variable categórica – Clase)
Regresión
(variable continua)
Clustering
Reglas de asociación
✓ Regresión Logística
✓ Arboles
✓ Redes Neuronales
✓ Gradient Boosting
✓ Random Forest
✓ SVM
✓ Naive Bayes
✓ KNN
Regresión lineal
Arboles
Redes Neuronales
Gradient Boosting
Random Forest
K-Means
Apriori

Árboles de decisión

CART

Un árbol de decisión que intenta imitar una serie de preguntas simples para llegar a una predicción.

Sirve para dos tipos de problemas: Clasificación y regresión

La idea clave: CART divide los datos en grupos homogeneos

Usamos el índice de Gini para construir el árbol que prediga con mayor exactitud

CART

Un árbol de decisión que intenta imitar una serie de preguntas simples para llegar a una predicción.

Sirve para dos tipos de problemas: Clasificación y regresión

La idea clave: CART divide los datos en grupos homogeneos

Usamos el índice de Gini para construir el árbol que prediga con mayor exactitud

¿Cual era el problema con CART?

CART - Desventajas

Propenso al sobreajuste (overfitting)

CART tiene una lógica de separar los datos hasta que queden grupos homogéneos

De esta manera, aprende *el ruido* de los datos de entrenamiento, y si le damos nuevos datos de testeo que varían un poco, probablemente los prediga mal

¿Qué técnica se usaba para reducir este overfitting? Pista: palabra en inglés

CART - Desventajas

Propenso al sobreajuste (overfitting)

CART tiene una lógica de separar los datos hasta que queden grupos homogéneos

De esta manera, aprende *el ruido* de los datos de entrenamiento, y si le damos nuevos datos de testeo que varían un poco, probablemente los prediga mal

¿Qué técnica se usaba para reducir este overfitting? Pista: palabra en inglés

Pruning

Métodos de ensamble

¿Qué significa para ustedes ensamblar modelos?

Métodos de ensamble

Técnicas de machine learning que combinan varios modelos para obtener una predicción mejor que la de un solo modelo.

Métodos de ensamble

Técnicas de machine learning que combinan varios modelos para obtener una predicción mejor que la de un solo modelo.

En vez de confiar en un solo modelo, hago muchos modelitos y promedio los resultados

Métodos de ensamble

Técnicas de machine learning que combinan varios modelos para obtener una predicción mejor que la de un solo modelo.

En vez de confiar en un solo modelo, hago muchos modelitos y promedio los resultados

Porque los modelos individuales pueden equivocarse, pero si sus errores son distintos, al combinarlos se puede obtener una predicción más estable y precisa.

Random Forest

Random Forest

Concepto básico: Un montón de árboles de decisión trabajando juntos

Cada árbol tiene una decisión final

Se promedian los resultados y gana la clase mayoritaria

Random Forest

¿Por qué funcionan bien?

Cada árbol ve los datos de manera diferente

Si hay errores, probablemente se cancelen entre sí, entonces el resultado es más robusto y estable

Random Forest

¿Por qué funcionan bien?

Cada árbol ve los datos de manera diferente

Si hay errores, probablemente se cancelen entre sí, entonces el resultado es más robusto y estable

Random Forest - Bootstrapping

Bootstrapping es una técnica para crear nuevas muestras a partir de un dataset original, tomando observaciones con reemplazo.

“Con reemplazo” significa que, después de elegir una observación, esta vuelve a estar disponible para ser elegida otra vez.

Por eso una misma fila puede aparecer varias veces en la muestra, y otra puede no aparecer.

Un bolillero, pero que devuelvo la bolilla despues de sacar un número

Datos normales

ID	Estudiante	Horas de estudio	Asistencia (%)	Nota final
1	Ana	2	70	58
2	Bruno	4	80	65
3	Carla	6	85	72
4	Diego	3	75	60
5	Elena	8	90	85
6	Fabio	5	82	68

Datos bootstrapeados

ID	Estudiante	Horas de estudio	Asistencia (%)	Nota final
1	Ana	2	70	58
2	Bruno	4	80	65
2	Bruno	4	80	65
4	Diego	3	75	60
5	Elena	8	90	85
1	Ana	2	70	58

Datos bootstrapeados

ID	Estudiante	Horas de estudio	Asistencia (%)	Nota final
1	Ana	2	70	58
2	Bruno	4	80	65
2	Bruno	4	80	65
4	Diego	3	75	60
5	Elena	8	90	85
1	Ana	2	70	58

Bootstrapping es **crear muchas versiones distintas de los datos** usando muestreo con reemplazo.

Random Forest

¿Por qué funcionan bien?

Cada árbol ve los datos de manera diferente

Si hay errores, probablemente se cancelen entre sí, entonces el resultado es más robusto y estable

Random Forest

¿Por qué funcionan bien?

Cada árbol ve los datos de manera diferente

Si hay errores, probablemente se cancelen entre sí, entonces el resultado es más robusto y estable

Bootstrapping + Selección de variables

Random Forest - Selección de variables

Cada nodo usa un subconjunto de variables para decidir como dividir

Cada decisión individual se toma mirando solo algunas variables candidatas.

Datos bootstrapeados

ID	Estudiante	Horas de estudio	Asistencia (%)	Trabajos entregados	Nota final
1	Ana	2	70	3	58
2	Bruno	4	80	5	65
2	Bruno	4	80	5	65
4	Diego	3	75	4	60
5	Elena	8	90	9	85
1	Ana	2	70	3	58

Datos bootstrapeados

ID	Horas de estudio	Asistencia (%)	Nota final
1	2	70	58
2	4	80	65
2	4	80	65
4	3	75	60
5	8	90	85
1	2	70	58

Datos bootstrapeados

ID	Estudiante	Horas de estudio	Asistencia (%)	Trabajos entregados	Nota final
2	Bruno	4	80	5	65
2	Bruno	4	80	5	65
5	Elena	8	90	9	85

Datos bootstrapeados

ID	Asistencia (%)	Trabajos entregados	Nota final
2	80	5	65
2	80	5	65
5	90	9	85

Random Forest

Random Forest = Bootstrapping + selección aleatoria de variables

Random Forest

Random Forest = Bootstrapping + selección aleatoria de variables

Random Forest → Utiliza Bagging

Bagging significa **Bootstrap Aggregating.**

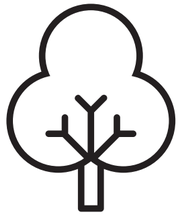
Es un método de ensamble que consiste en entrenar muchos modelos parecidos, pero usando distintas muestras de los datos, y luego combinar sus predicciones.

Random Forest

¿Cómo funciona?

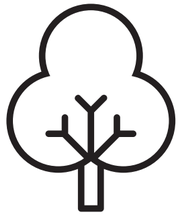
1. Se generan muestras bootstrap del dataset.
2. Para cada muestra se entrena un árbol.
3. En cada división del árbol, no se consideran todas las variables, sino un subconjunto aleatorio.
4. Se repite muchas veces, por ejemplo 100 a 1000 árboles.
5. La predicción final se decide por votación o promedio.

Random Forest

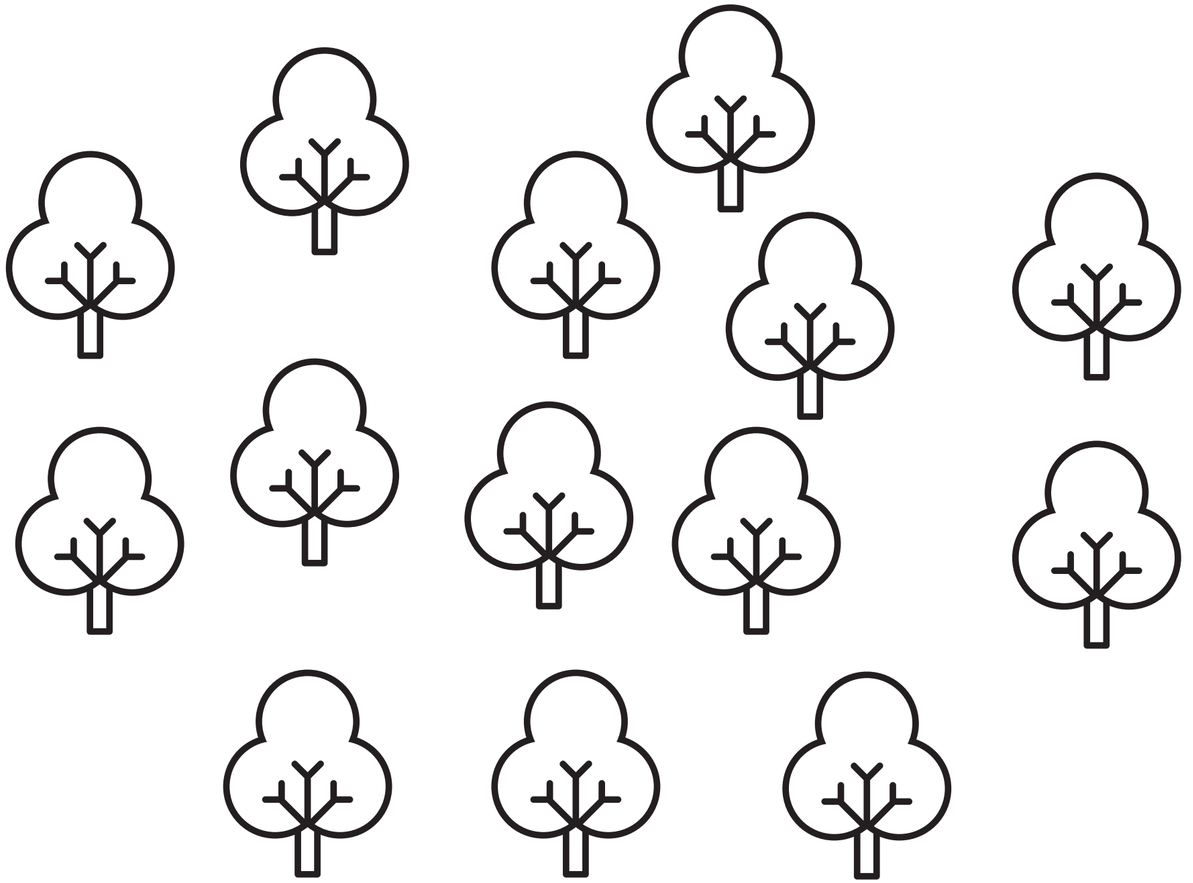


83% Accuracy

Random Forest

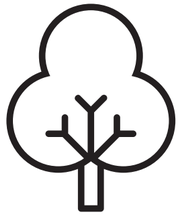


83% Accuracy



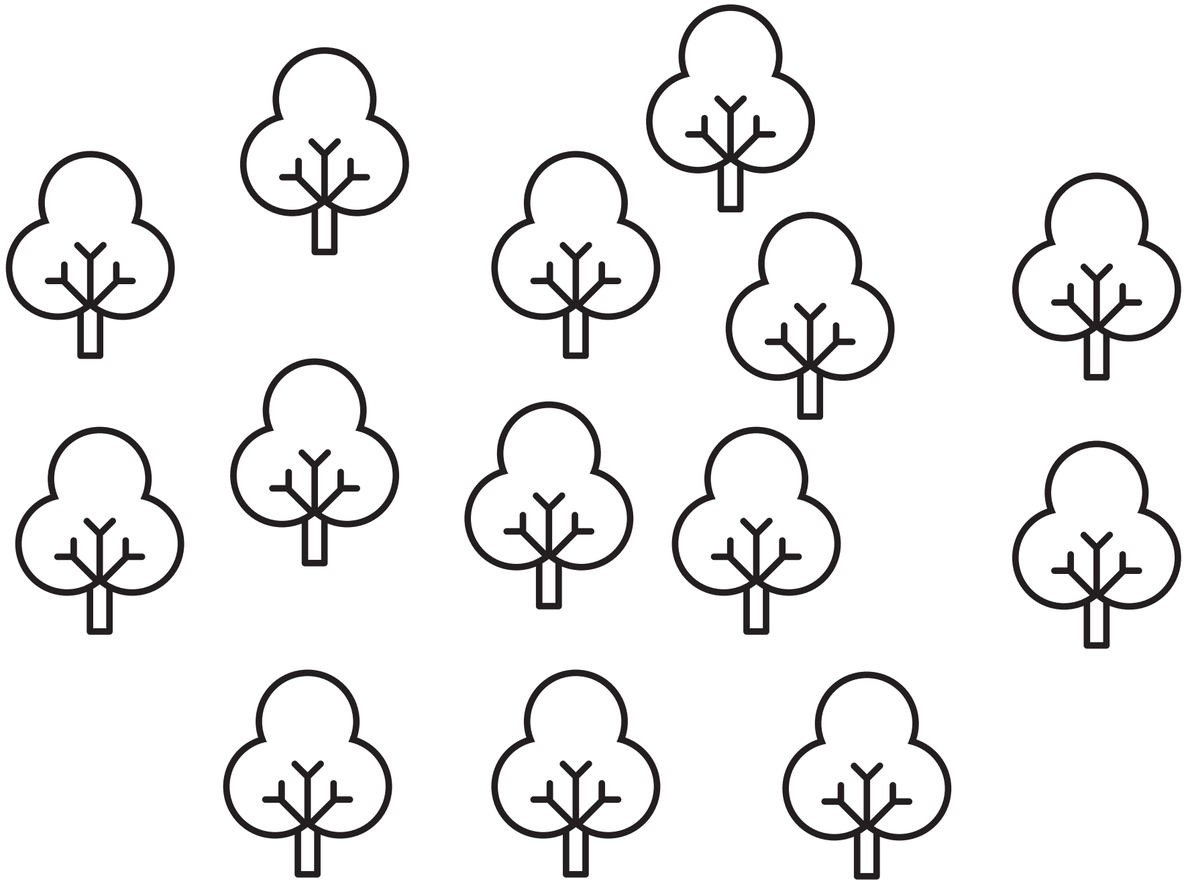
79% Accuracy

Random Forest



83% Accuracy





79% Accuracy



Random Forest - Características principales

- **Reduce el overfitting**: Al combinar muchos árboles, evita depender de un solo árbol demasiado ajustado a los datos.
- **Maneja variables numéricas y categóricas**: Puede trabajar con distintos tipos de variables.
- **Es robusto a outliers**: Los valores extremos afectan menos porque la decisión final sale de muchos árboles
- **Proporciona importancia de variables**: Permite ver qué variables aportan más a la predicción.
- **No necesita mucho preprocesamiento**: Suele funcionar bien sin escalar variables ni hacer transformaciones complejas
- **Es rápido / paralelizable**: Los árboles pueden entrenarse en paralelo, porque son relativamente independientes.

Random Forest - Parámetros

¿Qué era un parámetro?

n_estimators: Cantidad de árboles a entrenar.

max_features: Cantidad de variables consideradas en cada división del árbol.

max_depth: Profundidad máxima de cada árbol.

min_samples_split: Mínimo de muestras necesarias para dividir un nodo.

min_samples_leaf: Mínimo de muestras que debe haber en una hoja.

Random Forest - Parámetros

¿Qué era un parámetro?

```
RandomForestClassifier(
    n_estimators=100,
    max_features="sqrt",
   max_depth = 5
)
```

¿Qué otro método de ensamble podemos usar?

Random Forest & Boosting

Random forest construye muchos árboles de manera paralela, y los combina entre sí

Random Forest & Boosting

Random forest construye muchos árboles de manera **paralela**, y los combina entre sí

Boosting construye un arbol, y lo va mejorando **secuencialmente** aprendiendo de los errores anteriores

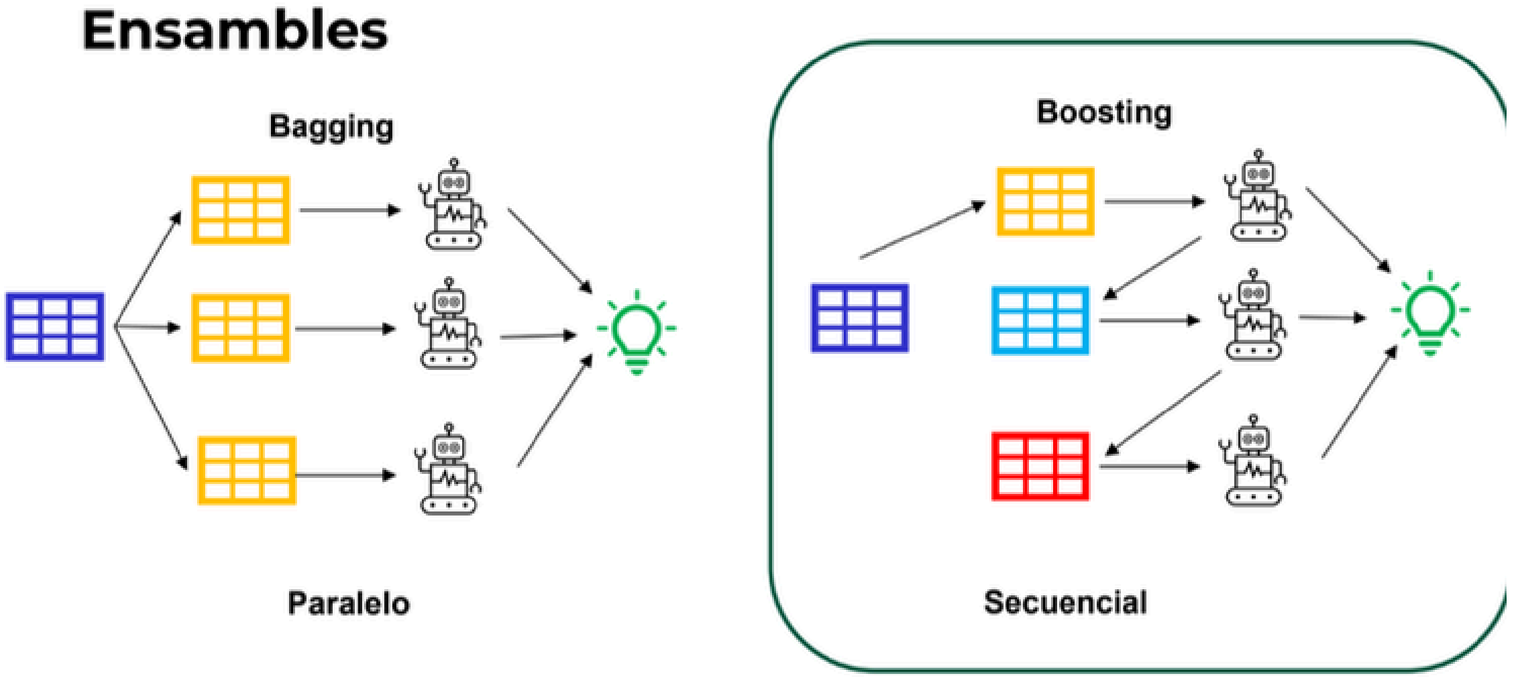
Boosting

Boosting es una técnica de ensamble que combina múltiples modelos “débiles” para crear un modelo “fuerte”

A diferencia de Random Forest, que construye árboles independientes en paralelo, Boosting construye modelos secuencialmente.

Boosting

A diferencia de Random Forest, que construye árboles independientes en paralelo, Boosting construye modelos secuencialmente.



Boosting

¿Cómo funciona?

1. Se entrena un primer árbol de decisión simple.
2. Se identifican los errores que cometió.
3. Se entrena un segundo árbol que intenta corregir esos errores.
4. Se repite el proceso, agregando nuevos árboles.
5. La predicción final combina los aportes de todos los árboles.

Boosting

¿Por qué funciona bien?

- Cada árbol se concentra en mejorar los errores anteriores.
- Muchos árboles simples pueden construir un modelo muy preciso.
- En lugar de entrenar árboles independientes, el modelo mejora progresivamente.

Boosting

Principales algoritmos

- **AdaBoost**: Los nuevos modelos prestan más atención a las observaciones donde los anteriores se equivocaron.
- **Gradient Boosting**: Cada nuevo árbol intenta corregir los errores de predicción acumulados.
- **XGBoost**: Una versión optimizada de Gradient Boosting, diseñada para mejorar la eficiencia y controlar el sobreajuste.

Situación	Mejor opción	¿Por qué?
Pocos hiperparámetros para ajustar	Random Forest	Buen rendimiento inicial
Maximizar Accuracy	XGBoost	Mayor potencial con tuning
Dataset pequeño y ruidoso	Random Forest	Mayor estabilidad
Dataset grande y complejo	XGBoost	Mejor capturando patrones complejos
Muchos outliers	Random Forest	Mayor robustez
Tiempo para Grid Search	XGBoost	Más posibilidades de optimización
Entrenamiento simple y rápido	Random Forest	Árboles independientes
Valores nulos	Ambos	Manejo nativo de nulos

Caso 1 — Random Forest

- Una universidad quiere predecir qué alumnos van a abandonar una materia utilizando asistencia, notas y cantidad de entregas.
- Tiene 1.000 observaciones y necesita un modelo confiable, sin dedicar demasiado tiempo a optimizarlo.
- Elegiría Random Forest como primera alternativa.

Caso 2 — XGBoost

- Un banco quiere predecir qué clientes van a incumplir el pago de un préstamo.
- Tiene 500.000 observaciones, muchas variables y recursos para optimizar el modelo.
- Probaría XGBoost porque puede ofrecer mejores resultados predictivos después de ajustar sus hiperparámetros.

Vamos a Python

